SAP projekt

2022-12-19

R Markdown

This is an R Markdown document. Markdown is a simple formatting syntax for authoring HTML, PDF, and MS Word documents. For more details on using R Markdown see http://rmarkdown.rstudio.com.

When you click the **Knit** button a document will be generated that includes both content as well as the output of any embedded R code chunks within the document. You can embed an R code chunk like this:

```
# Instalacija paketa
#install.packages("xlsx")
#install.packages("readxl")
#install.packages("stringr")
#install.packages("base")
#install.packages("magrittr")
#install.packages("ggplot2", dependencies = TRUE)
#install.packages("ggplot2")
#install.packages("gplots")
```

Učitavamo potrebne biblioteke.

```
library(dplyr)
library(stringr)
library(base)
library(magrittr)
library(xlsx)
library(readxl)
library(dplyr)
library(tidyverse)
library(gplots)
library(gsplot2)
library(broom)
library(readr)
library(purrr)
```

Pogledajmo podatke kojima raspolažemo. Stvaramo odgovarajuće dataframes čitajući iz datoteka fighter_details.csv i total_fight_data.csv.

```
fighter_data = read.csv("fighter_details.csv")
dim(fighter_data)

## [1] 3596    14
fight_data = read.csv("total_fight_data.csv" ,header = T,sep = ";")
```

Ukupno imamo 3596 registriranih boraca. Za njih je zabilježeno 14 atributa, a oni su:

```
names(fighter_data)
```

```
## [1] "fighter_name" "Height" "Weight" "Reach" "Stance"
```

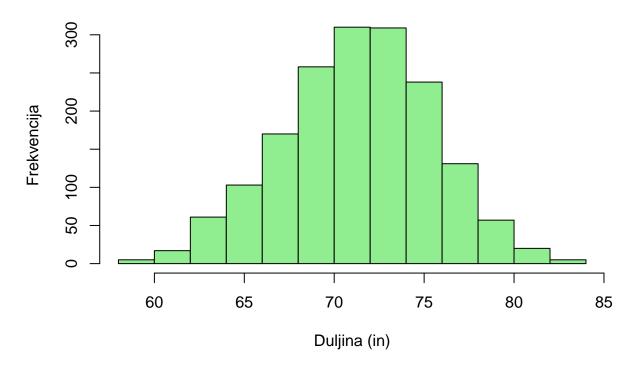
```
## [6] "DOB"
                        "MqJZ"
                                        "Str Acc"
                                                        "MqA2"
                                                                        "Str Def"
                                                        "Sub_Avg"
## [11] "TD_Avg"
                        "TD_Acc"
                                        "TD Def"
View(fighter_data)
sapply(fighter_data, class)
## fighter_name
                       Height
                                     Weight
                                                    Reach
                                                                Stance
                                                                                 DOB
##
    "character"
                  "character"
                               "character"
                                             "character"
                                                           "character"
                                                                         "character"
##
           SLpM
                      Str_Acc
                                       SApM
                                                 Str_Def
                                                                TD_Avg
                                                                              TD_Acc
##
      "numeric"
                  "character"
                                  "numeric"
                                             "character"
                                                             "numeric"
                                                                         "character"
##
         TD Def
                      Sub Avg
##
   "character"
                    "numeric"
```

Zadatak 1. Možemo li očekivati završetak borbe nokautom ovisno o razlici u dužini ruku između boraca?

Zanimaju nas borci koji imaju zabilježenu duljinu ruku.

Za početak nas zanima je li duljina ruku normalno distribuirana varijabla, što očekujemo da je.Potvrđujemo sa histogramom.

Histogram duljina ruku



Ovako izgledaju varijable objekta s kojim radimo.

```
fighter_reach_data = fighter_reach_data[c("fighter_name", "Reach")]
summary(fighter_reach_data)
```

```
fighter_name
                             Reach
##
    Length: 1684
                        Min.
                                :58.00
    Class : character
                        1st Qu.:69.00
##
##
    Mode :character
                        Median :72.00
##
                        Mean
                                :71.83
##
                        3rd Qu.:75.00
##
                        Max.
                                :84.00
```

Podatke o borbama provjeravamo za vrijednost win_by i redove s praznim vrijednostima izbacujemo. Zatim uzimamo samo atribute koji su potrebni za naš test (2 borca i tip pobjede)

```
fight_data[fight_data == ''] <- NA
for (col_name in names(fight_data)){
  if (sum(is.na(fight_data[,col_name])) > 0){
    cat('Ukupno nedostajućih vrijednosti za varijablu ',col_name, ': ', sum(is.na(fight_data[,col_name]))
}

## Ukupno nedostajucih vrijednosti za varijablu Referee : 32
## Ukupno nedostajucih vrijednosti za varijablu Winner... : 104
fight_data = fight_data[!is.na(fight_data$win_by),]
fight_data = fight_data[!is.na(fight_data$win_by),]
```

win_data <- fight_data[c("B_fighter", "R_fighter", "win_by")]</pre>

Moramo za svaku borbu u kojoj znamo raspon ruku oba borca grupirati razliku raspona u 2 grupe. Onu u kojoj je borba završila sa KO/TKO i u onu koju nije.

dif_KO1 = merge(win_data, fighter_reach_data, by.x = "B_fighter", by.y="fighter_name")

```
dif_KO = merge(dif_KO1, fighter_reach_data, by.x = "R_fighter", by.y="fighter_name")
dif_KO = dif_KO %>% filter(win_by == "KO/TKO")
dif_KO$dif = dif_KO$Reach.x - dif_KO$Reach.y

dif_else1 = merge(win_data, fighter_reach_data, by.x = "B_fighter", by.y="fighter_name")
dif_else = merge(dif_else1, fighter_reach_data, by.x = "R_fighter", by.y="fighter_name")
dif_else = dif_else %>% filter(win_by != "KO/TKO")
dif_else$dif = dif_else$Reach.x - dif_else$Reach.y

mean_KO <- mean(dif_KO$dif)
mean_else <- mean(dif_else$dif)
cat("Srednja vrijednost razlike raspona ruku ako borba nije završila nokautom na temelju uzorka:", mean</pre>
```

Srednja vrijednost razlike raspona ruku ako borba nije završila nokautom na temelju uzorka: 0.000597 cat("\n")

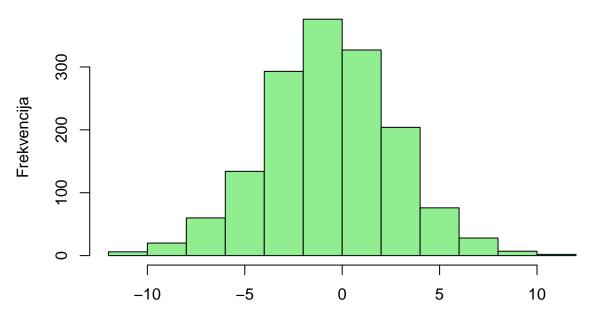
cat("Srednja vrijednost razlike raspona ruku ako je borba završila nokautom na temelju uzorka:", mean_KO

Srednja vrijednost razlike raspona ruku ako je borba završila nokautom na temelju uzorka: -0.1435095

Da bi smo mogli koristiti t-test kako bi analizirali razliku u srednjim vrijednostima naše dvije skupine prvo moramo provjeriti jesu li normalno distribuirane i je li F test zadovoljava jednakost o varijancama. Kako smo pokazali da je raspon ruku normalno distribuiran onda i razlika dvije vrijednosti te distribucije podliježe isto normalnoj distribuciji.

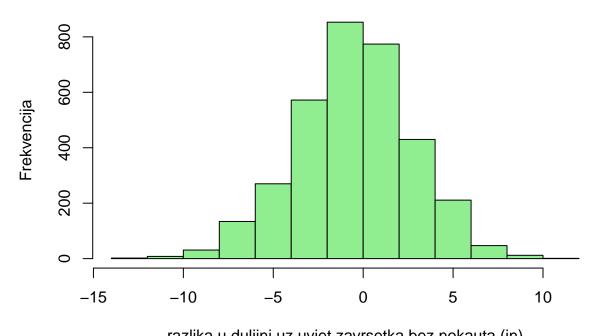
To se i vidi na histogramima u nastavku.

Histogram razlike duljina ruku



razlika u duljini uz uvjet zavrsetka nokautom (in)

Histogram razlike duljina ruku



razlika u duljini uz uvjet zavrsetka bez nokauta (in)

Sada postavljamo hipoteze o jednakosti varijanci za provođenje F-testa. H0 - varijance su jednake H1 - varijance nisu jednake

Provodimo test o jednakosti varijance kako bi znali koju vrstu t testa koristiti i na temelju dobivenih podataka zaključujemo da na razini značajnosti od 5% ne možemo odbaciti hipotezu da su varijance ova dva skupa jednake.

```
var.test(dif_KO$dif, dif_else$dif)
```

```
##
## F test to compare two variances
##
## data: dif_KO$dif and dif_else$dif
## F = 1.0521, num df = 1532, denom df = 3344, p-value = 0.241
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
## 0.9664972 1.1468285
## sample estimates:
## ratio of variances
## 1.052084
```

Sada možemo provesti t-test. Formiramo hipoteze. H0 - nema razlike u srednjim vrijednostima H1 - postoji razlika u srednjim vrijednostima

```
t.test(dif_KO$dif, dif_else$dif,var.equal=TRUE)
```

```
##
## Two Sample t-test
##
```

```
## data: dif_K0$dif and dif_else$dif
## t = -1.4355, df = 4876, p-value = 0.1512
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -0.34091321  0.05269848
## sample estimates:
## mean of x mean of y
## -0.1435094586  0.0005979073
```

Vidimo da je p vrijednost veća od 5% što znači da ovaj slučaj nema statističku važnost. Na razini 5% zaključujemo da ne možemo odbaciti hipotezu H0 te ju prihvaćamo da nema razlika u srednjim vrijednostima. Iz toga naknadno zaključujemo da ne možemo očekivati nokaut ovisno o razlici duljina ruku.

Zadatak 2. Razlikuje li se trajanje mečeva (u sekundama) između pojedinih kategorija?

#Razlika trajanja borbi ovisno o kategoriji

U ovom zadatku ćemo tražit postoji li razlika između trajanja borbi u sekundama ovisno o UFC kategoriji koja se natječe...

#1.Učitavanje podataka

```
total_fight_data_xlsx = suppressWarnings(read_excel("total_fight_data.xlsx"))

df = data.frame(total_fight_data_xlsx)

#total_fight_data = read.csv('total_fight_data.csv',header = T,sep = ";")
#write.xlsx(total_fight_data, "total_fight.xlsx")
#df <- read_excel("total_fight.xlsx")</pre>
```

Fight_type stupac je procesiran stupac koji opisuje koje je vrste borba te ćemo iz njega izvući kategoriju borbe Ukupnu sumu sekundi meča izvest ćemo zbrajanjem sekundi iz svake runde

#Sređivanje podataka

```
#Promotrit ćemo kakvo su strukturirane borbe po rundama
df$extracted <- str_extract(df$Format, "\\(([^)]+)\\)")</pre>
```

Trajanje runde je uvijek ograničeno s pet minuta...

```
sum(is.na(df[,"last_round_time"]))
```

```
## [1] 0
```

```
last_round_seconds <- rep(0, nrow(df))
df <- cbind(df, last_round_seconds)

for(index in seq_along(df)){
   time <- strptime(df[index, "last_round_time"], "%M:%S")
   seconds <- time$min * 60 + time$sec
   df[index, "last_round_seconds"] = seconds
}
df$last_round_seconds <- as.double(df$last_round_seconds)
df <- df %>%
   mutate(seconds_in_fight = (last_round - 1) * 5 * 60 + last_round_seconds)
```

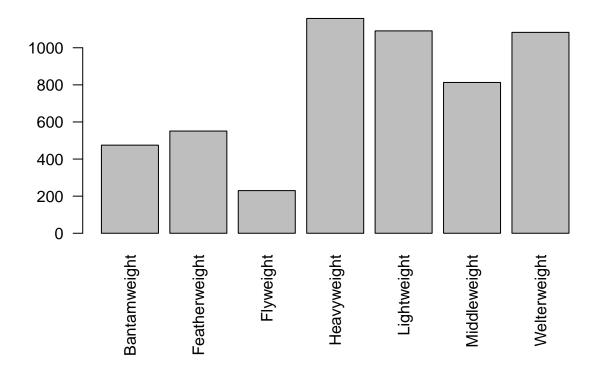
#update.packages()

Stvorili smo stupac koji opisuje ukupan broj sekundi trajanja borbe

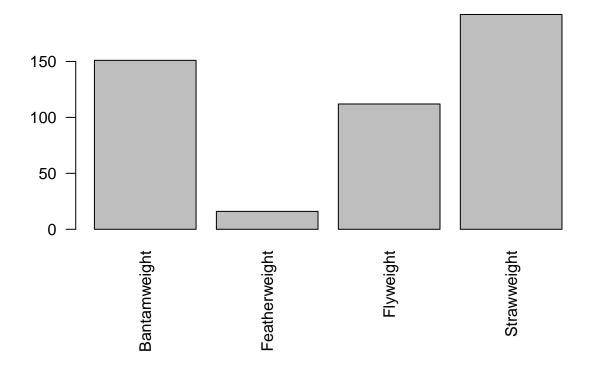
Treba urediti stupac "Fight type"...

Fight category appearances in man fights

barplot(table(df\$Fight_type[df\$Gender=="Man"]),las=2,cex.names=1,main='Fight category appearances in ma

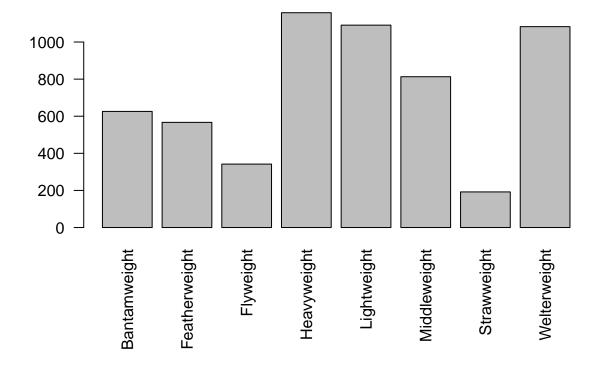


Fight category appearances in woman fights



barplot(table(df\$Fight_type),las=2,cex.names=1,main='Fight category appearances in all fights')

Fight category appearances in all fights



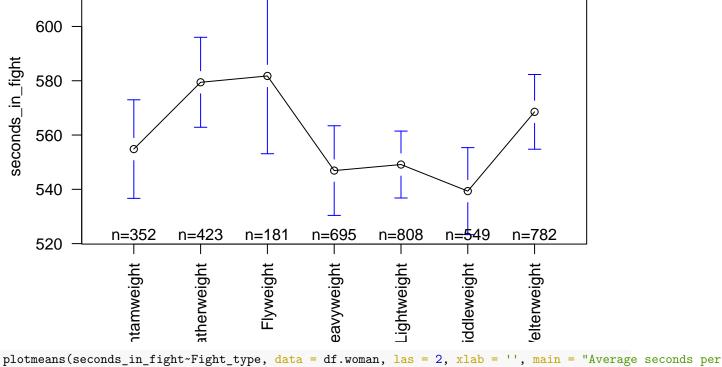
Puno je manje ženskih borbi te se točno pola od svih mogućih kategorija ne prikazuje...

```
#Brisanje borbi bez zapisa o vremenu trajanja

df.man <- filter(df, Gender == "Man")
    df.man <- filter(df.man, seconds_in_fight != 0)
    row_indexes <- complete.cases(df.man[, c("Fight_type", "seconds_in_fight")])
    df.man <- df.man[row_indexes, ]

df.woman <- filter(df, Gender == "Woman")
    df.woman <- filter(df.woman, seconds_in_fight != 0)
    row_indexes <- complete.cases(df.woman[, c("Fight_type", "seconds_in_fight")])
    df.woman <- df.woman[row_indexes, ]</pre>
plotmeans(seconds_in_fight~Fight_type, data = df.man, las = 2, xlab = '', main = "Average seconds per main trajanja.")
```

Average seconds per man fight compared for every category



```
## Warning in arrows(x, li, x, pmax(y - gap, li), col = barcol, lwd = lwd, :
```

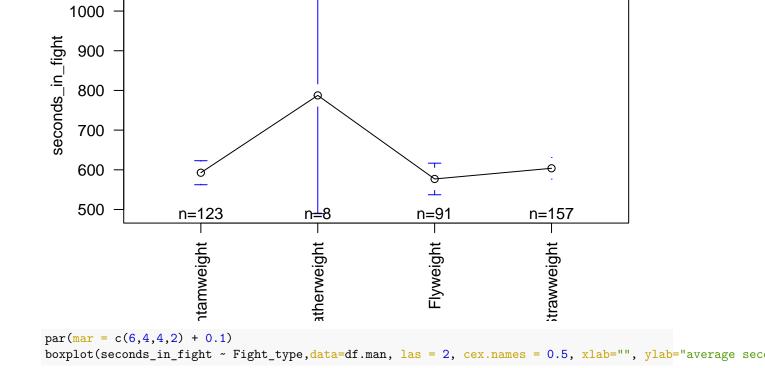
^{##} zero-length arrow is of indeterminate angle and so skipped

^{##} Warning in arrows(x, ui, x, pmin(y + gap, ui), col = barcol, lwd = lwd, :

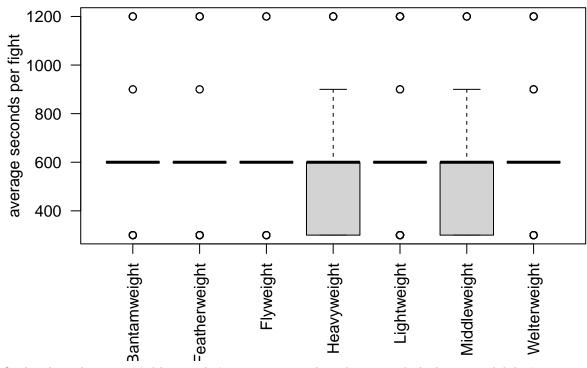
^{##} zero-length arrow is of indeterminate angle and so skipped

Average seconds per woman fight compared for every category

1100 -



Fight categories (man)



Ovakav box plot nije priželjkivan, ali ćemo ga ostaviti da prikazuje podatke koje smo dobili. Iz njega možemo isčitati da je median svake grupe 600 te je najčešći slučaj da je borba završena nakon druge runde.

#4.Provedba testova

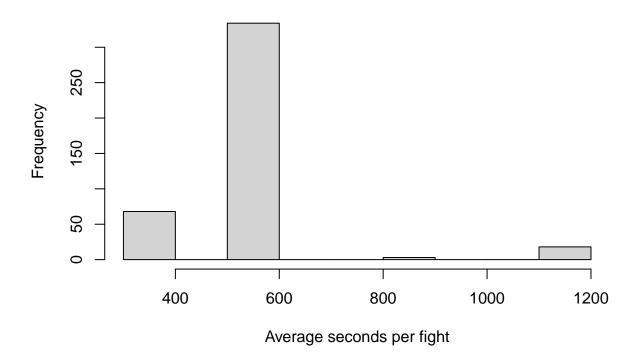
```
#4.1 Trajanje borbi kod muškaraca ovisno o kategoriji
```

```
#Provjera normalnosti zbog pretpostavke
require(nortest)
## Loading required package: nortest
lillie.test(df.man$seconds_in_fight)
##
##
   Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df.man$seconds_in_fight
## D = 0.35744, p-value < 2.2e-16
lillie.test(df.man$seconds_in_fight[df.man$Fight_type == "Heavyweight"])
##
##
   Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.man$seconds_in_fight[df.man$Fight_type == "Heavyweight"]
## D = 0.32913, p-value < 2.2e-16
lillie.test(df.man$seconds_in_fight[df.man$Fight_type == "Bantamweight"])
```

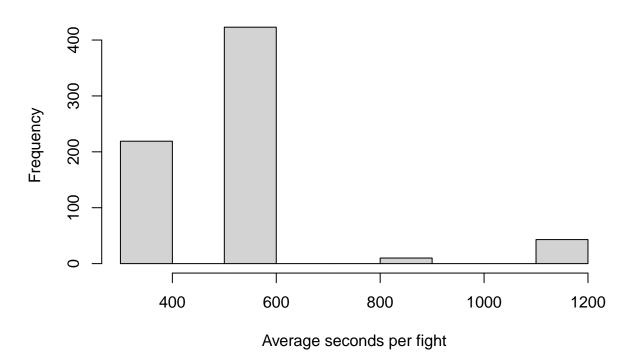
##

```
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df.man$seconds_in_fight[df.man$Fight_type == "Bantamweight"]
## D = 0.38127, p-value < 2.2e-16
lillie.test(df.man$seconds_in_fight[df.man$Fight_type == "Featherweight"])
##
   Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df.man$seconds in fight[df.man$Fight type == "Featherweight"]
## D = 0.40315, p-value < 2.2e-16
lillie.test(df.man$seconds_in_fight[df.man$Fight_type == "Flyweight"])
##
   Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df.man$seconds_in_fight[df.man$Fight_type == "Flyweight"]
## D = 0.40205, p-value < 2.2e-16
lillie.test(df.man$seconds_in_fight[df.man$Fight_type == "Lightweight"])
##
##
   Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.man$seconds_in_fight[df.man$Fight_type == "Lightweight"]
## D = 0.36958, p-value < 2.2e-16
lillie.test(df.man$seconds_in_fight[df.man$Fight_type == "Middleweight"])
##
##
   Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.man$seconds_in_fight[df.man$Fight_type == "Middleweight"]
## D = 0.3385, p-value < 2.2e-16
lillie.test(df.man$seconds_in_fight[df.man$Fight_type == "Welterweight"])
## Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.man$seconds_in_fight[df.man$Fight_type == "Welterweight"]
## D = 0.37487, p-value < 2.2e-16
#for (category in unique(df_man_fights$Fight_type)){
# lillie.test(df_man_fights$seconds_in_fight[df_man_fights$Fight_type==category])
#}
for (category in unique(df.man$Fight_type)){
  hist(df.man$seconds_in_fight[df.man$Fight_type==category], main = paste("Histogram of", category), x
)
}
```

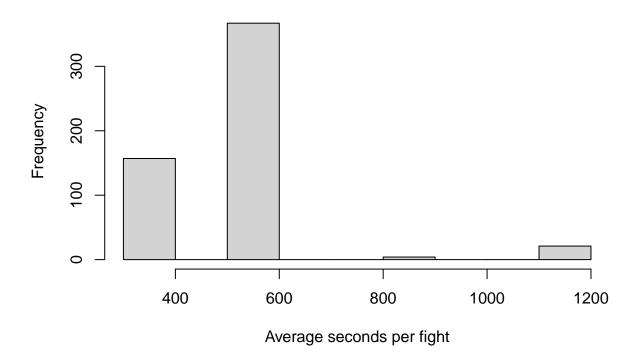
Histogram of Featherweight



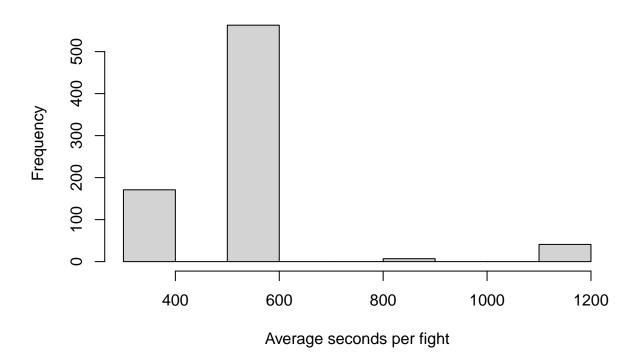
Histogram of Heavyweight



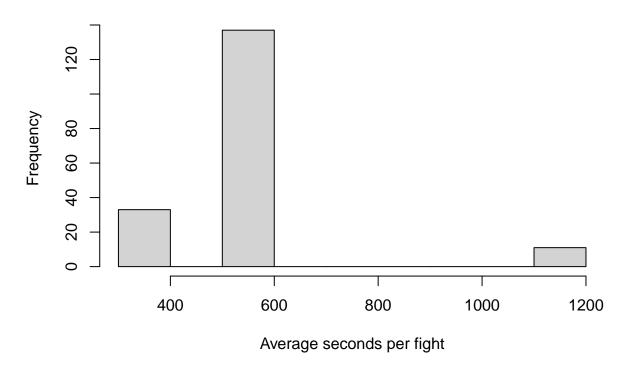
Histogram of Middleweight



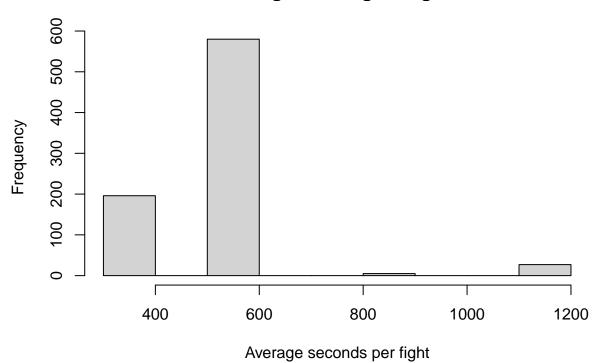
Histogram of Welterweight



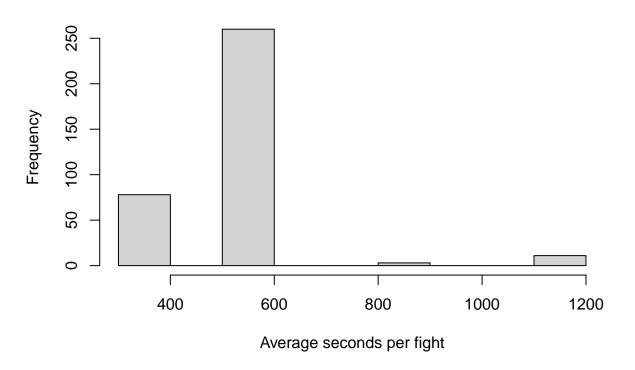
Histogram of Flyweight



Histogram of Lightweight



Histogram of Bantamweight



```
#Provjera homogenosti varijance zbog pretpostavke
bartlett.test(df.man$seconds_in_fight ~ df.man$Fight_type)
```

```
##
## Bartlett test of homogeneity of variances
##
## data: df.man$seconds_in_fight by df.man$Fight_type
## Bartlett's K-squared = 55.825, df = 6, p-value = 3.157e-10
var((df.man$seconds_in_fight[df.man$Fight_type=='Heavyweight']))
```

[1] 49179.9

Ne mozemo provest ANOVA test jer nam kategorije nemaju normalnu distribuciju niti homogenost varijance (pvalue testova je izrazito manji od 0.05). Provjerom normalnosti koja odbacuje samu normalnost zaključujemo da moramo korisit ne parametarske testove. Koristit cemo Kruskal-Wallisov test.

Unatoč neuspješnom dokazivanju normalnosti provest ćemo ANOVA test kako bismo razmotrili rezultat.

```
anova = aov(seconds_in_fight~Fight_type, data = df.man)
summary(anova)
```

```
## Df Sum Sq Mean Sq F value Pr(>F)
## Fight_type 6 721496 120249 3.25 0.00345 **
## Residuals 3783 139979232 37002
## ---
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' ' 1
```

```
kruskal.test(df.man$seconds_in_fight, df.man$Fight_type)
##
##
    Kruskal-Wallis rank sum test
##
## data: df.man$seconds_in_fight and df.man$Fight_type
## Kruskal-Wallis chi-squared = 32.39, df = 6, p-value = 1.373e-05
#4.2 Trajanje borbi kod žena ovisno o kategoriji
Featherweight borbi kod žena ima samo 9 pa ćemo njih isključit iz analize.
df.woman <- filter(df.woman, Fight type != "Featherweight")</pre>
lillie.test(df.woman$seconds_in_fight[df.woman$Fight_type == "Strawweight"])
##
##
    Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df.woman$seconds_in_fight[df.woman$Fight_type == "Strawweight"]
## D = 0.45148, p-value < 2.2e-16
lillie.test(df.woman$seconds_in_fight[df.woman$Fight_type == "Bantamweight"])
##
##
   Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.woman$seconds_in_fight[df.woman$Fight_type == "Bantamweight"]
## D = 0.434, p-value < 2.2e-16
lillie.test(df.woman$seconds_in_fight[df.woman$Fight_type == "Flyweight"])
##
##
    Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.woman$seconds_in_fight[df.woman$Fight_type == "Flyweight"]
## D = 0.39696, p-value < 2.2e-16
Distribucija kao i kod muškaraca nije normalna te koristimo ne parametarski test.
kruskal.test(df.woman$seconds_in_fight, df.woman$Fight_type)
##
    Kruskal-Wallis rank sum test
##
## data: df.woman$seconds_in_fight and df.woman$Fight_type
## Kruskal-Wallis chi-squared = 2.5917, df = 2, p-value = 0.2737
'Test pokazuje da nulta hipoteza da je razlika u trajanju borbi ovisno o kategoriji jednaka te ju ne možemo
odbaciti (p-value » 0.05).
#5.Dodatna provedba testa i zaključak Promatranjem podataka zaključuje se da se borbe dijele na one koje
traju 3 runde, jedne koje traju 5 rundi te još par vrsti koje imaju kombinaciju u strukturi samih rundi npr. "1
Rnd + 2OT (15-3-3)" "1 Rnd (12)". Taj faktor nam može biti utjecajan pri provedbi testa te ispitivanja
distribucije tako da ćemo dodatno promatrati samo one borbe koje traju 3 runde.
df.additional <- filter(df.man, Format == "3 Rnd (5-5-5)")
lillie.test(df.additional$seconds_in_fight)
##
```

Lilliefors (Kolmogorov-Smirnov) normality test

```
##
## data: df.additional$seconds in fight
## D = 0.47355, p-value < 2.2e-16
lillie.test(df.additional$seconds_in_fight[df.additional$Fight_type == "Heavyweight"])
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df.additional$seconds_in_fight[df.additional$Fight_type == "Heavyweight"]
## D = 0.43755, p-value < 2.2e-16
lillie.test(df.additional$seconds in fight[df.additional$Fight type == "Bantamweight"])
##
## Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.additional$seconds_in_fight[df.additional$Fight_type == "Bantamweight"]
## D = 0.4807, p-value < 2.2e-16
lillie.test(df.additional$seconds_in_fight[df.additional$Fight_type == "Featherweight"])
   Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df.additional$seconds_in_fight[df.additional$Fight_type == "Featherweight"]
## D = 0.50879, p-value < 2.2e-16
lillie.test(df.additional$seconds_in_fight[df.additional$Fight_type == "Flyweight"])
##
  Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.additional$seconds_in_fight[df.additional$Fight_type == "Flyweight"]
## D = 0.49899, p-value < 2.2e-16
lillie.test(df.additional$seconds_in_fight[df.additional$Fight_type == "Lightweight"])
##
## Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.additional$seconds_in_fight[df.additional$Fight_type == "Lightweight"]
## D = 0.47328, p-value < 2.2e-16
lillie.test(df.additional$seconds_in_fight[df.additional$Fight_type == "Middleweight"])
##
## Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.additional$seconds in fight[df.additional$Fight type == "Middleweight"]
## D = 0.45566, p-value < 2.2e-16
lillie.test(df.additional$seconds_in_fight[df.additional$Fight_type == "Welterweight"])
##
## Lilliefors (Kolmogorov-Smirnov) normality test
## data: df.additional$seconds_in_fight[df.additional$Fight_type == "Welterweight"]
## D = 0.48343, p-value < 2.2e-16
```

```
kruskal.test(df.additional$seconds_in_fight, df.additional$Fight_type)

##

## Kruskal-Wallis rank sum test

##

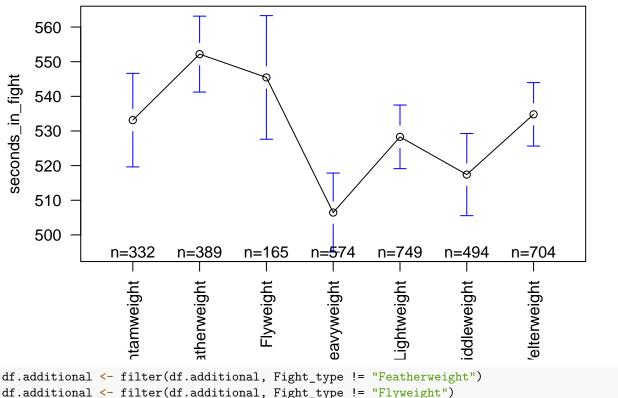
## data: df.additional$seconds_in_fight and df.additional$Fight_type

## Kruskal-Wallis chi-squared = 39.17, df = 6, p-value = 6.628e-07

Ne parametarski test nam govori da postoji razlika u trajanju borbi između kategorija.
```

Average seconds per man 3-round fight compared for every catego

plotmeans(seconds_in_fight~Fight_type, data = df.additional, las = 2, xlab = '', main = "Average second



```
df.additional <- filter(df.additional, Fight_type != "Flyweight")
df.additional <- filter(df.additional, Fight_type != "Heavyweight")
kruskal.test(df.additional$seconds_in_fight, df.additional$Fight_type)</pre>
```

```
##
## Kruskal-Wallis rank sum test
##
## data: df.additional$seconds_in_fight and df.additional$Fight_type
## Kruskal-Wallis chi-squared = 5.871, df = 3, p-value = 0.1181
```

Kada izbacimo kategorije koje nam 'iskaču' na grafu te usporedimo četiri kategorije (Bantamweight, Lightweight, Middleweight i Welterweight) i provedemo Kruskal-Wallisov test dobivamo p-vrijednost veću od 0.05 te dokazujemo da su nam razlike trajanja u sekundama približno jednake. Iz grafa vidimo da Featherweight i Flyweight kod muškaraca traju duže dok Heavyweight borbe traju najkraće.

Zadatak 3. Traju li (u rundama) borbe za titulu duže od ostalih borbi u natjecanju?

Moderni UFC razlikuje dva formata borbi: 3-Rnd (5-5-5) format od tri runde koji se koristi za obične borbe te 5-Rnd (5-5-5-5) format od 5 rundi koji se koristi za borbe za titulu. Naravno, bilo je situacija kada se 5-Rnd format koristio za obične borbe npr. UFC 202 borba Conor McGregora i Nate Diaza. Činjenica da borbe za titulu imaju prostora trajati dulje zbog formata nas motivira ispitati je li to istina. S jedne strane moramo biti svjesni činjenice da možda nećemo dobiti realnu sliku odnosa trajanja borbi jer su se mnoge 3-Rnd borbe koje su završile na odluku vjerojatno mogle produljiti. Iz tog razloga prvo ćemo usporediti trajanja u rundama neovisno o formatu, a zatim ćemo uspoređivati isključivo 5-Rnd borbe za titulu i 5-Rnd obične borbe jer ih ima podjednako.

Učitavamo podatke za sve borbe. Potom iz tih podataka stvaramo dva nova okvira od kojih jedan sadrži podatke za sve borbe za titulu, a drugi sadrži podatke za borbe koje nisu za titulu.

```
fight_data_task3 = suppressWarnings(read_excel("total_fight_data.xlsx"))

dfcopy_fight_data_task3 = data.frame(fight_data_task3);
dfcopy_fight_data_task3 <- subset(dfcopy_fight_data_task3, select = c(R_fighter, B_fighter, last_round,

# izdvajamo veliki dataset u dva manja radi lakšeg snalaženja

df_task3_titleFights = dfcopy_fight_data_task3 %>% filter(str_detect(Fight_type, "Title"))

df_task3_nonTitleFights = dfcopy_fight_data_task3 %>% filter(!str_detect(Fight_type, "Title"))

dfcopy_fight_data_task3$Fight_type[str_detect(dfcopy_fight_data_task3$Fight_type, "Title")] <- "Title B
dfcopy_fight_data_task3$Fight_type[!str_detect(dfcopy_fight_data_task3$Fight_type, "Title")] <- "Normal"</pre>
```

Vidimo da borbi za titulu ima značajno manje nego običnih borbi.

```
print(paste("Broj normalnih non-title borbi je: ", nrow(df_task3_nonTitleFights)))
```

```
## [1] "Broj normalnih non-title borbi je: 5647"
print(paste("Broj borbi za titulu je: ", nrow(df_task3_titleFights)))
```

```
## [1] "Broj borbi za titulu je: 365"
```

Cilj nam je provjeriti traju li borbe za titulu duže od ostalih borbi u natjecanju. Za navedeno istraživanje postavljamo kontingencijsku tablicu koja za stupce ima kategorijsku varijablu "Title bout" tj. "Bout".

Provjerimo prije svega koje formate borbi imamo u našem datasetu.

table(df_task3_nonTitleFights\$Format)

```
##
##
               1 Rnd (10)
                                         1 Rnd (12)
                                                                   1 Rnd (15)
##
                          6
                                                    4
                                                                             8
##
               1 Rnd (18)
                                         1 Rnd (20) 1 Rnd + 20T (15-3-3)
##
                                                   21
   1 \text{ Rnd} + 20T (24-3-3)
                                1 \text{ Rnd} + 0T (12-3)
                                                          1 Rnd + OT (15-3)
##
##
                                                   74
                                                                              2
##
       1 \text{ Rnd} + 0T (30-3)
                                1 \text{ Rnd} + 0T (30-5)
                                                          1 \text{ Rnd} + 0T (31-5)
##
                                                    1
                                                                              1
##
              2 Rnd (5-5)
                                     3 Rnd (5-5-5) 3 Rnd + OT (5-5-5-5)
##
                                                5252
##
       5 Rnd (5-5-5-5)
                                     No Time Limit
##
                        228
                                                   26
```

```
cat("\n")
table(df_task3_titleFights$Format)
##
                                                       1 Rnd + OT (12-3)
##
               1 Rnd (30) 1 Rnd + 20T (15-3-3)
##
##
       1 \text{ Rnd} + 0T (27-3)
                               1 \text{ Rnd} + 0T (30-5)
                                                            3 Rnd (5-5-5)
##
                                                                         37
                                                            No Time Limit
## 3 \text{ Rnd} + 0T (5-5-5-5)
                               5 Rnd (5-5-5-5)
##
```

Uočavamo da postoji dosta formata s izrazito malo održanih borbi. To su prastari formati koji se više ne koriste npr. 1 Rnd (12) format koji je korišten za samo 4 obične borbe. Takvi formati mogli bi utjecati na naše rezultate s obzirom da su limitirani na trajanje od samo jedne runde, a ona je trajala npr. 10 ili 20 minuta. Takve borbe mogle bi nam dati krivu sliku jer imaju određenu težinu u ovakvom istraživanju. Dodatna motivacija za eliminaciju borbi s prastarim formatima je ta što želimo da ovo istraživanje bude primjenjivo za budućnost UFC-a koji danas koristi isključivo 5-Rnd i 3-Rnd format. Imamo sreću što nećemo eliminirati veliki broj podataka. Potaknuti ovim zaključcima, modificiramo okvire da sadrže samo 3-Rnd i 5-Rnd formate koje ćemo potom uspoređivati.

```
dfcopy_fight_data_task3['Format'] <- sapply(dfcopy_fight_data_task3['Format'], as.character);
dfcopy_fight_data_task3 = dfcopy_fight_data_task3 %>% filter(grepl("5 Rnd (5-5-5-5-5)", Format, fixed =
```

Naši podaci su sada smanjeni s 6012 redaka na 5796, maknuli smo samo 3.5% podataka.

Pogledajmo sada koja sve trajanja natjecanja (u rundama) imamo za obje kategorije borbi.

```
levels(factor(df_task3_titleFights$last_round))
```

```
## [1] "1" "2" "3" "4" "5"
levels(factor(df_task3_nonTitleFights$last_round))
```

```
## [1] "1" "2" "3" "4" "5"
```

Vidimo da su u oba dataseta prisutna identična trajanja koja će u našem slučaju odgovarati redcima kontingencijske tablice. Kako bi si olakšali rad s podacima, pretvaramo podatke "last_round" u character format.

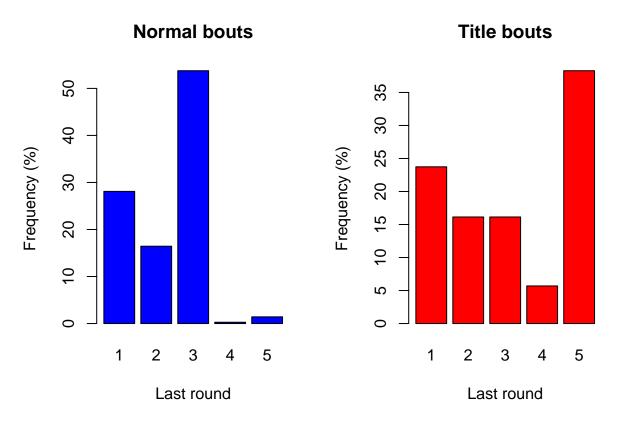
```
df_task3_titleFights['last_round'] <- sapply(df_task3_titleFights['last_round'], as.character)
df_task3_nonTitleFights['last_round'] <- sapply(df_task3_nonTitleFights['last_round'], as.character)
dfcopy_fight_data_task3['last_round'] <- sapply(dfcopy_fight_data_task3['last_round'], as.character)</pre>
```

Kreiramo kontingencijsku tablicu na temelju podataka.

```
dfcopy_fight_data_task3$last_round == "5",]$Fight_type)
tbl
##
##
       Normal Bout Title Bout
##
             1540
##
     2
               901
                           51
##
     3
              2946
                           51
                           18
##
     4
                15
                78
                          121
```

Dobra praksa je vizualizirati kategorijske podatke. Jedan on načina je da prikažemo odnose trajanja pomoću bar plota.

```
counts1 <- dfcopy_fight_data_task3 %>% filter(Fight_type == "Normal Bout") %>% count(last_round)
counts2 <- dfcopy_fight_data_task3 %>% filter(Fight_type == "Title Bout") %>% count(last_round)
counts1$pct <- counts1$n / sum(counts1$n) * 100</pre>
counts2$pct <- counts2$n / sum(counts2$n) * 100</pre>
par(mfrow=c(1, 2))
barplot(counts1$pct,
        names.arg=counts1$last_round,
        col="blue",
        main="Normal bouts",
        xlab="Last round",
        ylab="Frequency (%)",
        #legend=unique(counts$Fight_type)
barplot(counts2$pct,
        names.arg=counts2$last_round,
        col="red",
        main="Title bouts",
        xlab="Last round",
        ylab="Frequency (%)",
        #legend=unique(counts$Fight_type)
```



Na prvi pogled uočavamo da je u normalnim borbama najčešći slučaj da borba traje 3 runde. U slučajevima borbe za titulu najviše borbi završi u petoj rundi.

Tablici na kraju dodajemo margine.

78

5480

5

##

##

```
tbl_margins = addmargins(tbl)
tbl_margins
##
##
          Normal Bout Title Bout
                                     Sum
##
     1
                  1540
                                75 1615
     2
                   901
##
                                51
                                     952
     3
                  2946
                                51
                                    2997
##
     4
##
                    15
                                18
                                      33
```

Test nezavisnosti χ^2 test u programskom paketu R implementiran je u funkciji chisq.test() koja kao ulaz prima kontingencijsku tablicu podataka koje testiramo na nezavisnost. Ispitujemo nezavisnost trajanja borbe (u rundama) o vrsti borbe.

199

316 5796

121

Pretpostavka testa je da očekivana frekvencija pojedinog razreda mora biti veća ili jednaka 5 (chisq.test() pretpostavlja da je ovaj uvjet zadovoljen stoga je prije provođenja testa potrebno to provjeriti).

```
for (col_names in colnames(tbl_margins)){
  for (row_names in rownames(tbl_margins)){
    if (!(row_names == 'Sum' | col_names == 'Sum') ){
      cat('Očekivane frekvencije za razred ',col_names,'-',row_names,': ',(tbl_margins[row_names,'Sum'])
    }
```

```
}
```

```
## Ocekivane frekvencije za razred Normal Bout - 1 :
                                                     1526.95
## Ocekivane frekvencije za razred Normal Bout - 2:
                                                     900.0966
## Ocekivane frekvencije za razred
                                  Normal Bout - 3:
                                                     2833.602
## Ocekivane frekvencije za razred
                                  Normal Bout - 4:
                                                     31.20083
## Ocekivane frekvencije za razred
                                  Normal Bout - 5:
                                                    188.1504
## Ocekivane frekvencije za razred Title Bout - 1: 88.05038
## Ocekivane frekvencije za razred Title Bout - 2:
                                                    51.90338
## Ocekivane frekvencije za razred Title Bout - 3 :
## Ocekivane frekvencije za razred Title Bout - 4:
                                                    1.799172
## Ocekivane frekvencije za razred Title Bout - 5:
```

Uočavamo da nažalost pretpostavka testa nije ispunjena. Za slučaj "Title bout - 4" uočavamo da je očekivana frekvencija 1.799172 što je manje od 5. U ovakvoj situaciji ne možemo primjeniti χ^2 test nezavisnosti, ali nude nam se dva rješenja.

- 1. rješenje Možemo spajati dvije kategorije, u ovom slučaju pametan odabir bi bio spojiti borbe koje traju 4 i 5 rundi u jedno trajanje zvano "4-5". Motivacija za takvo spajanje je činjenica da su formati borbe ili 3-round ili 5-round, stoga ako je borba trajala dulje od 3 runde, spada u format 5 round.
- 2. rješenje Možemo umjesto χ^2 testa nezavisnosti koristiti Fisherov egzaktni test, koji je neparametarski i služi istoj svrsi kao i χ^2 test nezavisnosti.

Prvo ćemo pokazati rješenje pod 1. Moramo prvo modificirati vrijednosti gdje borbe traju 4 ili 5 rundi u "4-5"

```
##
##
         Normal Bout Title Bout
                                   Sum
##
     1
                 1540
                               75 1615
##
     2
                  901
                               51 952
     3
##
                 2946
                               51 2997
##
     4-5
                   93
                              139 232
##
                 5480
                              316 5796
```

tbl_combined_margins

Ponavljamo provjeru pretpostavke testa.

```
for (col_names in colnames(tbl_combined_margins)){
  for (row_names in rownames(tbl_combined_margins)){
    if (!(row_names == 'Sum' | col_names == 'Sum') ){
      cat('Očekivane frekvencije za razred ',col_names,'-',row_names,': ',(tbl_combined_margins[row_names])
  }
}
```

```
## Ocekivane frekvencije za razred Normal Bout - 1 : 1526.95
## Ocekivane frekvencije za razred Normal Bout - 2 : 900.0966
## Ocekivane frekvencije za razred Normal Bout - 3 : 2833.602
## Ocekivane frekvencije za razred Normal Bout - 4-5 : 219.3513
## Ocekivane frekvencije za razred Title Bout - 1 : 88.05038
## Ocekivane frekvencije za razred Title Bout - 2 : 51.90338
## Ocekivane frekvencije za razred Title Bout - 3 : 163.3975
## Ocekivane frekvencije za razred Title Bout - 4-5 : 12.64872
```

Sve su frekvencije veće od 5 pa konačno možemo provesti test. Formirajmo sada hipoteze: H0 - trajanja borbe (u rundama) su jednaka za obje vrste borbi H1 - trajanja borbe (u rundama) nisu jednaka za obje vrste borbi

```
chisq.test(tbl_combined,correct=F)
```

```
##
## Pearson's Chi-squared test
##
## data: tbl_combined
## X-squared = 1418.8, df = 3, p-value < 2.2e-16</pre>
```

Odbacujemo pretpostavku H0 - "trajanja borbe (u rundama) su jednaka za obje vrste borbi" u svrhu H1 - "trajanja borbe (u rundama) nisu jednaka za obje vrste borbi". ## Drugo rješenje je korištenje Fisherovog egzaktnog testa, te koristimo tbl koji smo ranije definirali.

```
fisher.test(tbl, simulate.p.value=TRUE)
```

```
##
## Fisher's Exact Test for Count Data with simulated p-value (based on
## 2000 replicates)
##
## data: tbl
## p-value = 0.0004998
## alternative hypothesis: two.sided
```

Odbacujemo pretpostavku H0 - "trajanja borbe (u rundama) su nezavisna o vrsti borbe" u svrhu H1 - "trajanja borbe (u rundama) su zavisna o vrsti borbe".

Ponovimo sada statističko istraživanje tako da uspoređujemo isključivo 5-Rnd borbe u obje kategorije borbi.

Format "5 Rnd (5-5-5-5)" je popularan u borbama za titulu (279 borbi), a dovoljno popularan u normalnim borbama (228 borbi). S obzirom da je broj borbi tog formata za obje kategorije velik i ne previše različit, filtrirat ćemo podatke koje imamo i ponoviti istraživanje samo nad borbama formata "5 Rnd (5-5-5-5)".

```
df5rndFormat_fight_data_task3 = data.frame(dfcopy_fight_data_task3)
df5rndFormat_fight_data_task3['Format'] <- sapply(df5rndFormat_fight_data_task3['Format'], as.character
df5rndFormat_fight_data_task3 = df5rndFormat_fight_data_task3 %>% filter(grepl("5 Rnd (5-5-5-5-5))", Format')
```

Kreiramo tablicu za borbe formata "5 Rnd (5-5-5-5)".

```
tbl_5rnd = table(df5rndFormat_fight_data_task3[df5rndFormat_fight_data_task3$last_round == "1" |
                                               df5rndFormat_fight_data_task3$last_round == "2" |
                                               df5rndFormat_fight_data_task3$last_round == "3" |
                                               df5rndFormat_fight_data_task3$last_round == "4" |
                                               df5rndFormat_fight_data_task3$last_round == "5",]$last_r
            df5rndFormat_fight_data_task3[df5rndFormat_fight_data_task3$last_round == "1" |
                                          df5rndFormat fight data task3$last round == "2" |
                                          df5rndFormat_fight_data_task3$last_round == "3" |
                                          df5rndFormat_fight_data_task3$last_round == "4" |
                                          df5rndFormat_fight_data_task3$last_round == "5",]$Fight_type)
tbl_5rnd_margins = addmargins(tbl_5rnd)
tbl_5rnd_margins
##
##
         Normal Bout Title Bout Sum
##
     1
                             63 133
                  70
##
     2
                  41
                             43 84
##
     3
                  24
                             34 58
##
     4
                  15
                             18 33
##
     5
                  78
                            121 199
     Sum
                 228
                            279 507
Provjeravamo očekivane frekvencije.
for (col_names in colnames(tbl_5rnd_margins)){
  for (row_names in rownames(tbl_5rnd_margins)){
    if (!(row_names == 'Sum' | col_names == 'Sum') ){
      cat('Očekivane frekvencije za razred ',col_names,'-',row_names,': ',(tbl_5rnd_margins[row_names,'
   }
  }
}
## Ocekivane frekvencije za razred Normal Bout - 1: 59.81065
## Ocekivane frekvencije za razred Normal Bout - 2: 37.77515
## Ocekivane frekvencije za razred Normal Bout - 3 : 26.08284
## Ocekivane frekvencije za razred Normal Bout - 4: 14.84024
## Ocekivane frekvencije za razred Normal Bout - 5: 89.49112
## Ocekivane frekvencije za razred
                                    Title Bout - 1: 73.18935
## Ocekivane frekvencije za razred
                                    Title Bout - 2 :
                                                      46.22485
## Ocekivane frekvencije za razred
                                    Title Bout - 3 :
                                                      31.91716
## Ocekivane frekvencije za razred
                                    Title Bout - 4: 18.15976
## Ocekivane frekvencije za razred Title Bout - 5: 109.5089
Pretpostavka testa je ispunjena pa ga provodimo.
chisq.test(tbl_5rnd, correct=F)
##
##
  Pearson's Chi-squared test
##
## data: tbl_5rnd
## X-squared = 6.6414, df = 4, p-value = 0.1561
```

Zanimljivo, ovakvo istraživanje nam je dalo drugačiji zaključak. Ne možemo odbaciti hipotezu H0 - "trajanja borbe (u rundama) su jednaka za obje vrste borbi" te ju prihvaćamo s obzirom na p-vrijednost i vrijednost statistike manje od kritične vrijednosti. Mogli smo pretpostaviti da ćemo doći do ovakvog zaključka gledajući

kontingencijsku tablicu za "5 Rnd" format borbe jer je za isto trajanje borbe u obje kategorije podjednak broj opaženih borbi.

Zadatak 4. Mogu li dostupne značajke predvidjeti pobjednika??

Zadatak je odrediti može li se predvidjeti pobjednik UFC borbe pomoću dostupnih značajki. To ćemo napraviti pomoću modela logističke regresije. Za regresore ćemo samo koristiti značajke dostupne prije borbe, npr: tip borbe, težine borca, postotak obaranja u borbama borca itd. a nećemo koristiti značajke dobivene tijekom borbe: značajni udarci itd. Napraviti ćemo nekoliko modela, svaki sa različitim pristupom, a svaki pristup ćemo objasniti prije stvaranja modela. Idemo prvo urediti naš dataset. Prvo učitavamo podatke o svim borbama koje imamo:

Iz te tablice uzimamo samo 4 stupca: B_Fighter, R_Fighter, Fight_type i Winner. Ostale značajke su dobivene tijekom borbe ili ne bi smjele utjecati na pobjednika(datum, lokacija...). Ako je pobjednik crveni, Winner mijenjamo u 0, a ako je plavi u 1. Stupci Winner i Fight_Type ćemo transformirati u tip varijable faktor

```
suppressWarnings({
    fightdata=read_excel("total_fight_data.xlsx")
})
fightdata <- filter(fightdata, !is.na(Winner) & !is.na(R_fighter) & !is.na(B_fighter) ) #izbriši redove
fightdataprocessed=select(fightdata,R_fighter,B_fighter,Fight_type,Winner)
fightdataprocessed$Winner=factor(ifelse(fightdataprocessed$Winner == fightdataprocessed$R_fighter, 0, 1
fightdataprocessed$Winner=factor(fightdataprocessed$Winner)
fightdataprocessed$Fight_type=factor(fightdataprocessed$Fight_type)
summary(fightdataprocessed)</pre>
```

```
##
    R_fighter
                        B_fighter
                                                             Fight_type
                                                                           Winner
   Length:5902
                       Length:5902
                                           Lightweight Bout
                                                                           0:3979
##
                                                                   :1030
                        Class : character
                                           Welterweight Bout
                                                                           1:1923
   Class : character
                                                                   :1010
                                           Middleweight Bout
   Mode :character
##
                                                                   : 759
                       Mode :character
##
                                           Heavyweight Bout
                                                                   : 518
##
                                           Featherweight Bout
                                                                   : 517
##
                                           Light Heavyweight Bout: 507
                                            (Other)
##
                                                                   :1561
```

Koristiti ćemo nekoliko različitih modela, koje ćemo pri kraju usporediti.

Sad ćemo izvaditi podatke o borcima , te odmah urediti(postotke iz stringa u decimalne brojeve, visinu,težinu i doseg u brojeve itd.,Stance u faktor tip varijable)

```
fightersdata=read.csv("fighter_details.csv")

fightersdata=select(fightersdata,-DOB) #mičemo datum rođenja

fightersdata <- filter(fightersdata, nchar(as.character(fightersdata$Reach)) > 0) #makni redove gdje n

fightersdata <- filter(fightersdata, nchar(as.character(fightersdata$Height)) > 0) #makni redove gdje

fightersdata <- filter(fightersdata, nchar(as.character(fightersdata$Stance)) > 0) #nmakni redove gdje

fightersdata$Str_Acc=parse_number(fightersdata$Str_Acc)/100 #pretvori postotke u decimale

fightersdata$Str_Def=parse_number(fightersdata$Str_Def)/100

fightersdata$Weight=parse_number(fightersdata$Weight)
```

```
fightersdata$Reach=parse_number(fightersdata$Reach)
fightersdata$TD_Acc=parse_number(fightersdata$TD_Acc)/100
fightersdata$TD_Def=parse_number(fightersdata$TD_Def)/100
# kod pronađen na internetu, za konverziju visine iz incha u centimetre
# Split height column into feet and inches columns
fightersdata <- fightersdata %>%
 mutate(feet = str_split(Height, " ") %>% map_chr(1),
        inches = str_split(Height, ' ') %>% map_chr(2))
fightersdata$feet=parse number(fightersdata$feet)
fightersdata$inches=parse_number(fightersdata$inches)
# Convert feet to inches and add to inches column
fightersdata$total_inches <- fightersdata$feet * 12 + fightersdata$inches
# Convert total inches to centimeters
fightersdata$height_cm <- fightersdata$total_inches * 2.54
# Remove unnecessary columns
fightersdata <- fightersdata %>%
 select(-feet, -inches, -total_inches, -Height)
fightersdata$Stance=factor(fightersdata$Stance)
summary(fightersdata)
## fighter_name
                          Weight
                                          Reach
                                                             Stance
## Length:1664
                                             :58.00
                                                      Open Stance:
                      Min.
                             :115.0
                                      Min.
## Class :character
                      1st Qu.:135.0
                                      1st Qu.:69.00
                                                      Orthodox
                                                                :1247
## Mode :character Median :155.0
                                      Median :72.00
                                                     Southpaw
                                                                : 316
##
                      Mean
                             :164.8
                                      Mean
                                            :71.84
                                                      Switch
##
                      3rd Qu.:185.0
                                      3rd Qu.:75.00
##
                             :265.0
                                             :84.00
                      Max.
                                     Max.
##
        SLpM
                       Str_Acc
                                          SApM
                                                         Str_Def
                           :0.0000 Min.
                                           : 0.000
##
   Min.
          : 0.000
                    Min.
                                                     Min.
                                                            :0.0000
   1st Qu.: 2.270
                    1st Qu.:0.3800
                                    1st Qu.: 2.470
                                                     1st Qu.:0.4800
##
                    Median :0.4400
## Median : 3.135
                                    Median : 3.190
                                                     Median : 0.5500
                                           : 3.499
## Mean
         : 3.292
                    Mean
                           :0.4402
                                     Mean
                                                     Mean
                                                            :0.5343
##
   3rd Qu.: 4.053
                    3rd Qu.:0.5000
                                     3rd Qu.: 4.150
                                                      3rd Qu.:0.6000
                          :0.8800
## Max.
          :19.910
                    Max.
                                    Max.
                                           :23.330
                                                     Max.
                                                            :0.8600
       TD_Avg
##
                        TD Acc
                                         TD Def
                                                       Sub_Avg
## Min.
          : 0.000
                    Min.
                           :0.0000
                                    Min.
                                           :0.000
                                                    Min.
                                                           : 0.0000
## 1st Qu.: 0.430
                    1st Qu.:0.2000
                                                    1st Qu.: 0.0000
                                     1st Qu.:0.380
## Median : 1.180
                    Median :0.3500
                                     Median :0.600
                                                    Median : 0.4000
## Mean
         : 1.534
                    Mean
                           :0.3572
                                     Mean
                                           :0.546
                                                    Mean
                                                          : 0.6534
## 3rd Qu.: 2.300
                    3rd Qu.:0.5000
                                     3rd Qu.:0.750
                                                    3rd Qu.: 0.9000
```

:

Max.

Max.

Min.

##

:18.000

:152.4

height_cm

1st Qu.:172.7 ## Median :177.8 ## Mean :178.0 Max. :1.0000

:1.000

Max.

:20.4000

```
## 3rd Qu.:185.4
## Max. :210.8
```

Vrijeme je za izradu prvog modela logističke regresije. Tablicu s podacima za model ćemo dobiti tako što spojimo fighterdata sa fightdataprocessed pomoću funkcije merge, prvo spajajući po crvenom kutu, zatim plavom, te za oba borca i u plavom i u crvenom kutu gledamo pojedinačno njihove značajke, svaku kao stupac. X varijabla će predstavljati crveni kut, dok će y varijabla predstavljati plavi kut. Ovaj model će koristiti sve moguće značajke pri predviđanju(osim imena)

```
privremena1=merge(fightdataprocessed,fightersdata,by.x="R_fighter",by.y="fighter_name")
final_data1=merge(privremena1,fightersdata,by.x="B_fighter",by.y="fighter_name")
summary(final_data1)
```

```
##
     B_fighter
                          R_fighter
                                                                Fight_type
                                                                               Winner
##
    Length: 4864
                         Length: 4864
                                              Lightweight Bout
                                                                      : 854
                                                                               0:3071
##
                                                                               1:1793
    Class : character
                         Class : character
                                              Welterweight Bout
                                                                      : 836
##
    Mode :character
                                                                        608
                         Mode :character
                                              Middleweight Bout
##
                                              Featherweight Bout
                                                                        468
##
                                              Light Heavyweight Bout: 438
##
                                              Bantamweight Bout
                                                                      : 398
##
                                              (Other)
                                                                      :1262
                                                             SLpM.x
##
       Weight.x
                       Reach.x
                                           Stance.x
##
    Min.
            :115
                   Min.
                           :60.0
                                    Open Stance: 11
                                                         Min.
                                                                : 0.000
##
    1st Qu.:145
                   1st Qu.:70.0
                                    Orthodox
                                                         1st Qu.: 2.590
                                                :3663
##
    Median:170
                   Median:72.0
                                    Southpaw
                                                :1039
                                                         Median : 3.260
                                                : 151
                                                                : 3.389
##
    Mean
            :168
                   Mean
                           :72.2
                                    Switch
                                                         Mean
##
    3rd Qu.:185
                   3rd Qu.:75.0
                                                         3rd Qu.: 4.070
##
    Max.
            :265
                   Max.
                           :84.0
                                                         Max.
                                                                 :19.910
##
##
      Str_Acc.x
                           SApM.x
                                           Str_Def.x
                                                               TD_Avg.x
##
            :0.0000
                              : 0.100
                                         Min.
                                                 :0.1800
                                                                    :0.000
##
    1st Qu.:0.3900
                       1st Qu.: 2.440
                                         1st Qu.:0.5300
                                                            1st Qu.:0.680
##
    Median : 0.4400
                       Median : 3.010
                                         Median :0.5700
                                                            Median :1.420
                              : 3.168
##
    Mean
            :0.4409
                                         Mean
                       Mean
                                                 :0.5648
                                                            Mean
                                                                    :1.661
##
    3rd Qu.:0.4900
                       3rd Qu.: 3.780
                                         3rd Qu.:0.6100
                                                            3rd Qu.:2.390
##
    Max.
            :0.7700
                              :23.330
                                         Max.
                                                 :0.8600
                                                            Max.
                                                                    :8.330
                      Max.
##
##
                          \mathtt{TD}_{\mathtt{Def.x}}
       TD_Acc.x
                                           Sub_Avg.x
                                                             height_cm.x
##
            :0.0000
                              :0.0000
                                                                    :152.4
                       Min.
                                         Min.
                                                 :0.0000
                                                            Min.
##
    1st Qu.:0.3000
                       1st Qu.:0.5300
                                         1st Qu.:0.2000
                                                            1st Qu.:172.7
##
    Median :0.4000
                       Median :0.6300
                                         Median :0.5000
                                                            Median :177.8
##
    Mean
            :0.4005
                       Mean
                               :0.6193
                                         Mean
                                                 :0.6707
                                                            Mean
                                                                    :178.6
##
    3rd Qu.:0.5000
                       3rd Qu.:0.7500
                                         3rd Qu.:1.0000
                                                            3rd Qu.:185.4
##
    Max.
            :1.0000
                               :1.0000
                                         Max.
                                                 :7.4000
                                                                    :210.8
                      Max.
                                                            Max.
##
##
       Weight.y
                         Reach.y
                                               Stance.y
                                                                SLpM.y
##
            :115.0
                             :58.00
                                       Open Stance:
                                                                  : 0.180
                     Min.
                                                            Min.
##
    1st Qu.:145.0
                                                            1st Qu.: 2.498
                      1st Qu.:70.00
                                       Orthodox
                                                   :3669
##
    Median :155.0
                     Median :72.00
                                       Southpaw
                                                   : 986
                                                            Median : 3.220
                                                   : 205
##
    Mean
            :167.5
                     Mean
                             :72.16
                                       Switch
                                                            Mean
                                                                    : 3.324
##
    3rd Qu.:185.0
                     3rd Qu.:75.00
                                                            3rd Qu.: 4.032
##
            :265.0
                     Max.
                             :84.00
                                                            Max.
                                                                    :15.070
##
##
      Str_Acc.y
                           SApM.y
                                            Str_Def.y
                                                               TD_Avg.y
```

```
Min.
           :0.1000
                             : 0.100
                                               :0.1900
                                                                 : 0.000
##
                      Min.
                                       Min.
                                                         Min.
##
    1st Qu.:0.3900
                      1st Qu.: 2.530
                                       1st Qu.:0.5100
                                                          1st Qu.: 0.610
   Median :0.4400
                      Median : 3.095
                                       Median :0.5600
                                                         Median : 1.270
           :0.4359
                            : 3.327
                                                                 : 1.536
##
   Mean
                     Mean
                                       Mean
                                               :0.5522
                                                         Mean
##
    3rd Qu.:0.4800
                      3rd Qu.: 3.900
                                       3rd Qu.:0.6000
                                                          3rd Qu.: 2.220
           :0.8800
                             :21.180
                                               :0.7800
                                                                 :10.860
##
   {\tt Max.}
                      Max.
                                       Max.
                                                         Max.
##
##
       TD_Acc.y
                         TD_Def.y
                                         Sub_Avg.y
                                                         height_cm.y
##
    Min.
           :0.0000
                      Min.
                             :0.000
                                      Min.
                                              :0.0000
                                                        Min.
                                                                :152.4
##
    1st Qu.:0.2700
                      1st Qu.:0.500
                                       1st Qu.:0.1000
                                                         1st Qu.:172.7
##
    Median :0.3800
                      Median :0.620
                                       Median :0.5000
                                                        Median :177.8
           :0.3819
                             :0.597
                                                                :178.7
##
    Mean
                      Mean
                                       Mean
                                              :0.6464
                                                        Mean
##
    3rd Qu.:0.5000
                      3rd Qu.:0.750
                                       3rd Qu.:0.9000
                                                        3rd Qu.:185.4
   Max.
           :1.0000
                             :1.000
                                              :7.4000
##
                      Max.
                                       Max.
                                                        Max.
                                                                :210.8
##
```

Vrijeme je za regresiju, jedino ćemo prije nje za faktorske varijable Stance.x i Stance.y, odlučiti da je referentni level Stance Orthodox, pošto je najfrekventniji, jer bi model trebao bit precizniji ako za faktorsku varijablu odaberem referentni level koji je najfrekventniji.

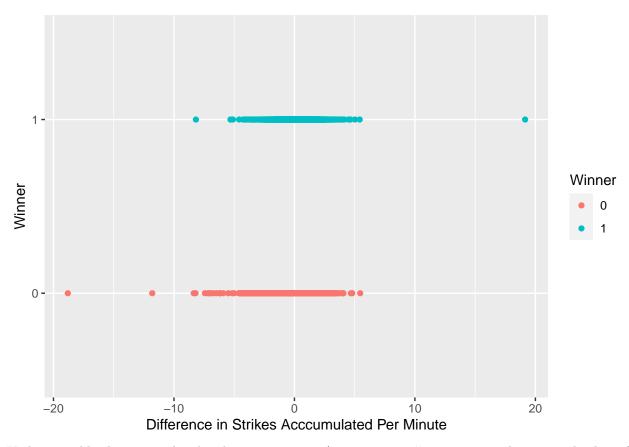
```
final_data1$Stance.x = relevel(final_data1$Stance.x, ref = "Orthodox")
final_data1$Stance.y = relevel(final_data1$Stance.y, ref = "Orthodox")
logreg.mdl1 = glm(Winner ~Fight_type + Weight.x + Reach.x +Stance.x+ SLpM.x+Str_Acc.x + SApM.x + Str_De summary(logreg.mdl1)
#output ovog summary ne izbacujemo u pdf jer zauzima 10+ stranica

Rsq1 = 1 - logreg.mdl1$deviance/logreg.mdl1$null.deviance
cat("Rsq1: ",Rsq1)
```

Rsq1: 0.1141735

Možemo primijetiti da su neki regresori znatno bitniji od drugih, napravimo graf gdje ćemo vidjeti razliku između pojedinih regresora i utjecaj na pobjednika

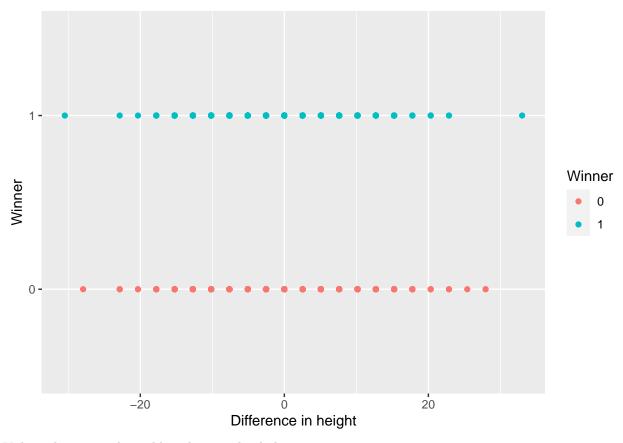
```
ggplot(data = final_data1, aes(x = SApM.x-SApM.y, y = Winner, color = Winner)) +
  geom_point() +
  labs(x = "Difference in Strikes Accoumulated Per Minute", y = "Winner")
```



Kada je razlika broja primljenih udaraca po minuti(regresor s značajnom p vrijednosti za oba borca) negativan, znači da je plavi borac primio više udaraca, i vidimo na grafu da onda imamo više crvenih pobjednika, dok pozitivna razlika znači da je crveni primio više udaraca, te imamo više plavih pobjednika.

Usporedimo to s visinom, regresorom koji nema značajnu p vrijednost

```
ggplot(data = final_data1, aes(x = height_cm.x-height_cm.y, y = Winner, color = Winner)) +
geom_point() +
labs(x = "Difference in height", y = "Winner")
```



Vidimo da nema neke razlike u broju pobjednika.

Gledajući grafove, možemo zaključiti da neki regresori nisu značajni. Preko funkcije step s parametrom backward ćemo sada napraviti reducirani model sa značajnijim regresorima

```
logreg.mdl2=step(logreg.mdl1,direction = "backward",trace=0)
summary(logreg.mdl2)
```

```
##
## Call:
  glm(formula = Winner ~ Weight.x + Reach.x + SLpM.x + Str_Acc.x +
       SApM.x + Str_Def.x + TD_Avg.x + TD_Def.x + Sub_Avg.x + height_cm.x +
##
##
       Weight.y + Reach.y + SLpM.y + SApM.y + TD_Avg.y + TD_Acc.y +
##
       TD_Def.y, family = binomial(), data = final_data1)
##
##
  Deviance Residuals:
##
       Min
                 1Q
                      Median
                                    3Q
                                            Max
           -0.9304
                    -0.6597
                                1.1465
                                         2.3854
##
   -2.7873
##
## Coefficients:
##
                Estimate Std. Error z value Pr(>|z|)
## (Intercept) -0.187695
                           1.197423
                                     -0.157 0.875443
               -0.008810
                           0.003193
                                     -2.759 0.005803 **
## Weight.x
## Reach.x
               -0.039967
                           0.017800
                                     -2.245 0.024748 *
                                     -6.139 8.32e-10 ***
## SLpM.x
               -0.252709
                           0.041166
## Str_Acc.x
               -1.145054
                           0.552902
                                     -2.071 0.038360 *
## SApM.x
                0.277273
                                      6.072 1.26e-09 ***
                           0.045664
## Str_Def.x
               -2.118148
                           0.614129 -3.449 0.000563 ***
```

```
-0.094105
                           0.029775
                                     -3.161 0.001575 **
## TD Avg.x
## TD_Def.x
               -0.790281
                                     -4.136 3.54e-05 ***
                           0.191079
## Sub_Avg.x
               -0.246962
                           0.053658
                                     -4.603 4.17e-06 ***
## height_cm.x 0.012694
                           0.008875
                                      1.430 0.152650
## Weight.y
                0.004705
                           0.003190
                                      1.475 0.140186
                0.031658
                           0.013030
                                      2.430 0.015118 *
## Reach.y
## SLpM.y
                0.435848
                           0.033636
                                     12.958 < 2e-16 ***
## SApM.y
               -0.289144
                           0.035662
                                     -8.108 5.15e-16 ***
## TD_Avg.y
                0.157506
                           0.029909
                                      5.266 1.39e-07 ***
## TD_Acc.y
               -0.753340
                           0.184924
                                     -4.074 4.63e-05 ***
## TD_Def.y
                1.085076
                           0.168117
                                      6.454 1.09e-10 ***
##
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
##
   (Dispersion parameter for binomial family taken to be 1)
##
##
       Null deviance: 6403.2 on 4863
                                       degrees of freedom
## Residual deviance: 5781.1
                              on 4846
                                       degrees of freedom
  AIC: 5817.1
##
##
## Number of Fisher Scoring iterations: 4
Rsq2 = 1 - logreg.mdl2$deviance/logreg.mdl2$null.deviance
cat("Rsq2: ",Rsq2)
```

Rsq2: 0.097148

Dobijamo model s većom rezidualnom devijancom nego naš početni model. Provesti ćemo Likelihood Ratio Test, i ako se ispostavi da se rezidualna devijanca nije previše povećala(provjeravamo preko p vrijednosti), uzet ćemo reducirani model kao bolji

```
anova(logreg.mdl1, logreg.mdl2, test = "LRT")
```

```
## Analysis of Deviance Table
##
## Model 1: Winner ~ Fight_type + Weight.x + Reach.x + Stance.x + SLpM.x +
       Str_Acc.x + SApM.x + Str_Def.x + TD_Avg.x + TD_Acc.x + TD_Def.x +
##
##
       Sub_Avg.x + height_cm.x + Weight.y + Reach.y + Stance.y +
##
       SLpM.y + Str_Acc.y + SApM.y + Str_Def.y + TD_Avg.y + TD_Acc.y +
##
       TD_Def.y + Sub_Avg.y + height_cm.y
##
  Model 2: Winner ~ Weight.x + Reach.x + SLpM.x + Str_Acc.x + SApM.x + Str_Def.x +
##
       TD_Avg.x + TD_Def.x + Sub_Avg.x + height_cm.x + Weight.y +
##
       Reach.y + SLpM.y + SApM.y + TD_Avg.y + TD_Acc.y + TD_Def.y
##
     Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1
          4765
                   5672.1
## 2
          4846
                   5781.1 -81 -109.02 0.02068 *
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
```

No, provedbom LRT vidimo da se rezidualna devijanca povećala, i to na razini značajnosti manjoj od 0.05, pa ne možemo koristiti reducirani model umjesto opširnog. Tu smo probali i neke druge modele, gdje bi micali samo jedan ili 2 regresora, no ni oni nisu zadovoljili na LRT, pa ih nismo ostavili u projektu.

Provjerimo sada koliko je model uspješan u predviđanju. Koristićemo "matricu zabune". Njezini parametri: - accuracy: $\frac{TP+TN}{TP+FP+TN+FN}$ - precision: $\frac{TP}{TP+FP}$ - recall: $\frac{TP}{TP+FN}$ - specificity: $\frac{TN}{TN+FP}$

Sto su parametri veći, model uspješnije predviđa

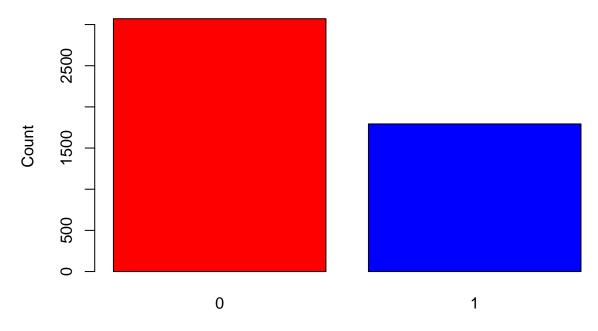
```
yHat <- logreg.mdl1$fitted.values >= 0.5
tab <- table(final_data1$Winner, yHat)</pre>
tab
##
      yHat
##
       FALSE TRUE
##
     0 2679 392
##
     1 1110 683
accuracy1 = sum(diag(tab)) / sum(tab)
precision1 = tab[2,2] / sum(tab[,2])
recall1 = tab[2,2] / sum(tab[2,])
specificity1 = tab[1,1] / sum(tab[,1])
cat("Accuracy: ",accuracy1,"\n")
## Accuracy: 0.6912007
cat("Precision: ",precision1,"\n")
## Precision: 0.6353488
cat("Recall: ",recall1,"\n")
## Recall: 0.3809258
cat("Specificity: ",specificity1,"\n")
```

Specificity: 0.7070467

Od naših borbi u datasetu, oko 3001 je pobjedio crveni, a 1793 je pobijedio plavi. Naš model od 3071 pobjede crvenog njih oko 2670(oko 2670) zato jer ponovnim pokretanjem bilježnice se dobivaju blago promijenjenje vrijednosti) klasificira točno, dok od 1793 pobjede plavih samo oko 680 klasificira kao pobjedu plavih. To je vidljivo i u niskoj vrijednosti recall varijabli.

```
barplot(table(final_data1$Winner),
    col = c("red","blue"),
    main = "Winner, 0 = Red, 1 = Blue",
    xlab = "Winner of the fight in dataset",
    ylab = "Count")
```

Winner, 0 = Red, 1 = Blue



Winner of the fight in dataset

Tu se može doći do zanimljive pretpostavke, a to je da naš model u većini slučajeva samo pretpostavi da je crveni pobjednik, tj. da ima "bias" prema crvenom. S obzirom da je praksa UFC da stavlja svoje favorite u crveni kut, ovu pretpostavku treba provjeriti. Kako to testirati, i kako poboljšati model ako je to istina. Naša je ideja bila da prođemo kroz cijeli dataset, i onda za svaku slučajnu borbu zamijenimo kuteve boraca, i njihovu statistiku. Npr, ako pomoću random funkcije odlučimo da se mijenjanju, B_Fighter postaje R Fighter, te sve varijable koje su imale .y na kraju postaju .x. Provedimo to.

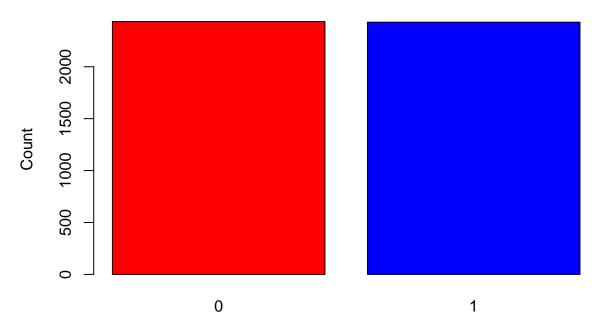
```
fightdataprocessed2=fightdataprocessed
for(i in 1:nrow(fightdataprocessed2)){
  random_number <- sample(0:1,1)
  if(random_number==1){
    row=fightdataprocessed2[i,]
    storage=row$R_fighter
    row$R_fighter=row$B_fighter
    row$B_fighter=storage
    row$Winner=factor(ifelse(row$Winner==0,1,0))
    fightdataprocessed2[i,]=row
}
summary(fightdataprocessed2)</pre>
```

```
##
     R_fighter
                         B_fighter
                                                              Fight_type
                                                                            Winner
##
    Length:5902
                        Length:5902
                                            Lightweight Bout
                                                                    :1030
                                                                            0:2923
##
    Class :character
                        Class :character
                                            Welterweight Bout
                                                                    :1010
                                                                            1:2979
##
    Mode :character
                        Mode : character
                                            Middleweight Bout
                                                                    : 759
##
                                            Heavyweight Bout
                                                                    : 518
```

```
##
                                            Featherweight Bout
                                                                    : 517
##
                                            Light Heavyweight Bout: 507
##
                                            (Other)
privremena2=merge(fightdataprocessed2,fightersdata,by.x="R_fighter",by.y="fighter_name")
final_data3=merge(privremena2,fightersdata,by.x="B_fighter",by.y="fighter_name")
summary(final data3)
##
     B fighter
                         R fighter
                                                              Fight_type
                                                                            Winner
##
    Length: 4864
                        Length: 4864
                                            Lightweight Bout
                                                                    : 854
                                                                            0:2435
    Class : character
                        Class : character
                                            Welterweight Bout
                                                                    : 836
                                                                            1:2429
                        Mode :character
##
    Mode :character
                                            Middleweight Bout
                                                                      608
##
                                            Featherweight Bout
                                                                    : 468
##
                                            Light Heavyweight Bout: 438
##
                                            Bantamweight Bout
                                                                    : 398
##
                                            (Other)
                                                                    :1262
##
       Weight.x
                        Reach.x
                                             Stance.x
                                                              SLpM.x
##
                            :60.00
                                      Open Stance:
                                                                  : 0.000
           :115.0
                     Min.
                                                          Min.
    1st Qu.:145.0
                     1st Qu.:70.00
                                      Orthodox
                                                          1st Qu.: 2.550
                                                  :3640
##
    Median :155.0
                     Median :72.00
                                      Southpaw
                                                  :1042
                                                          Median: 3.250
##
    Mean
           :167.6
                     Mean
                            :72.19
                                      Switch
                                                  : 174
                                                          Mean
                                                                  : 3.367
##
    3rd Qu.:185.0
                     3rd Qu.:75.00
                                                          3rd Qu.: 4.050
##
    Max.
           :265.0
                     Max.
                            :84.00
                                                          Max.
                                                                  :15.070
##
##
      Str_Acc.x
                          SApM.x
                                          Str Def.x
                                                             TD_Avg.x
##
           :0.0000
                             : 0.100
                                                :0.1900
                                                                  : 0.0000
    1st Qu.:0.3900
                      1st Qu.: 2.500
                                                          1st Qu.: 0.6475
##
                                        1st Qu.:0.5200
##
    Median :0.4400
                      Median : 3.040
                                        Median :0.5600
                                                          Median: 1.3600
##
    Mean
           :0.4382
                      Mean
                             : 3.259
                                        Mean
                                                :0.5591
                                                          Mean
                                                                  : 1.6061
    3rd Qu.:0.4800
                      3rd Qu.: 3.830
                                        3rd Qu.:0.6100
                                                          3rd Qu.: 2.3200
##
    Max.
           :0.8800
                      Max.
                             :23.330
                                        Max.
                                                :0.7800
                                                          Max.
                                                                  :10.8600
##
##
       TD_Acc.x
                         {\tt TD\_Def.x}
                                         Sub_Avg.x
                                                          height_cm.x
    Min.
           :0.0000
                      Min.
                             :0.000
                                       Min.
                                              :0.0000
                                                         Min.
                                                                 :152.4
    1st Qu.:0.2900
##
                      1st Qu.:0.500
                                       1st Qu.:0.1000
                                                         1st Qu.:172.7
                      Median :0.630
##
    Median :0.3900
                                       Median :0.5000
                                                         Median :177.8
##
           :0.3927
                             :0.606
                                                         Mean
                                                                :178.7
    Mean
                      Mean
                                       Mean
                                              :0.6579
    3rd Qu.:0.5000
                      3rd Qu.:0.750
                                       3rd Qu.:1.0000
                                                         3rd Qu.:185.4
                                              :7.4000
##
    Max.
           :1.0000
                      Max.
                             :1.000
                                       Max.
                                                         Max.
                                                                 :210.8
##
##
       Weight.y
                        Reach.y
                                             Stance.y
                                                              SLpM.y
                                                          Min. : 0.180
##
    Min.
           :115.0
                            :58.00
                                      Open Stance:
                     Min.
##
    1st Qu.:145.0
                     1st Qu.:70.00
                                      Orthodox
                                                  :3692
                                                          1st Qu.: 2.558
##
    Median :170.0
                     Median :72.00
                                      Southpaw
                                                  : 983
                                                          Median : 3.240
    Mean
           :167.9
                     Mean
                            :72.17
                                      Switch
                                                  : 182
                                                          Mean
                                                                 : 3.346
    3rd Qu.:185.0
                     3rd Qu.:75.00
                                                          3rd Qu.: 4.053
##
    Max.
           :265.0
                     Max.
                            :84.00
                                                          Max.
                                                                  :19.910
##
##
      Str_Acc.y
                          SApM.y
                                          Str_Def.y
                                                             TD_Avg.y
##
                             : 0.100
                                                                  :0.000
    Min.
           :0.1200
                      Min.
                                        Min.
                                                :0.1800
                                                          Min.
##
    1st Qu.:0.3900
                      1st Qu.: 2.480
                                        1st Qu.:0.5200
                                                          1st Qu.:0.660
    Median :0.4400
                      Median : 3.060
                                        Median :0.5600
                                                          Median :1.320
    Mean
           :0.4386
                      Mean
                             : 3.236
                                        Mean
                                               :0.5579
                                                          Mean
                                                                  :1.591
```

```
3rd Qu.:0.4900
                      3rd Qu.: 3.840
                                       3rd Qu.:0.6100
                                                         3rd Qu.:2.320
##
           :0.8800
##
    Max.
                             :11.900
                                       Max.
                                               :0.8600
                                                                 :8.330
                      Max.
                                                         Max.
##
##
                         TD_Def.y
       TD_Acc.y
                                         Sub_Avg.y
                                                          height_cm.y
##
    Min.
           :0.0000
                      Min.
                             :0.0000
                                       Min.
                                               :0.0000
                                                         Min.
                                                                 :152.4
    1st Qu.:0.2800
                      1st Qu.:0.5100
                                       1st Qu.:0.1000
                                                         1st Qu.:172.7
##
    Median :0.3900
                      Median :0.6300
                                       Median :0.5000
                                                         Median :177.8
##
##
    Mean
           :0.3897
                      Mean
                             :0.6103
                                       Mean
                                               :0.6592
                                                         Mean
                                                                 :178.6
##
    3rd Qu.:0.5000
                      3rd Qu.:0.7500
                                       3rd Qu.:0.9000
                                                         3rd Qu.:185.4
##
    Max.
           :1.0000
                      Max.
                             :1.0000
                                       Max.
                                               :7.4000
                                                         Max.
                                                                 :210.8
##
barplot(table(final_data3$Winner),
        col = c("red","blue"),
        main = "Winner, 0 = Red, 1 = Blue",
        xlab = "Winner of the fight in dataset",
        ylab = "Count")
```

Winner, 0 = Red, 1 = Blue



Winner of the fight in dataset

Primjećujemo da sada imamo podjednak broj pobjednika u plavom i crvenom kutu. Idemo sada napraviti model logističke regresije.

```
final_data3$Stance.x = relevel(final_data3$Stance.x, ref = "Orthodox")
final_data3$Stance.y = relevel(final_data3$Stance.y, ref = "Orthodox")
logreg.mdl5 = glm(Winner ~Fight_type + Weight.x + Reach.x +Stance.x+ SLpM.x+Str_Acc.x + SApM.x + Str_Desummary(logreg.mdl5)
#output ovog summary ne izbacujemo u pdf jer zauzima 10+ stranica
```

```
Rsq5 = 1 - logreg.mdl5$deviance/logreg.mdl5$null.deviance
cat("Rsq5: ",Rsq5)
```

Rsq5: 0.1124208

Primjećujemo da ovakav model ima lošije parametre od početnog, kao npr. AIC, Residual deviance, Rsq, no moramo uzeti u obzir da je i dataset drukčiji, te da nema "biasa" prema crvenom.

Provjerimo je li ovim pristupom reducirani model moguć.

```
logreg.mdl6=step(logreg.mdl5,direction = "backward",trace=0)
summary(logreg.mdl6)
```

```
##
## Call:
  glm(formula = Winner ~ Weight.x + Reach.x + SLpM.x + Str_Acc.x +
##
       SApM.x + Str_Def.x + TD_Avg.x + TD_Acc.x + TD_Def.x + Sub_Avg.x +
##
       Weight.y + Reach.y + SLpM.y + SApM.y + Str_Def.y + TD_Avg.y +
##
       TD_Def.y + Sub_Avg.y, family = binomial(), data = final_data3)
##
## Deviance Residuals:
                      Median
##
       Min
                                   3Q
                 10
                                           Max
  -2.2930
            -1.0695
                     -0.1629
                               1.0744
                                        2.3990
##
## Coefficients:
##
                Estimate Std. Error z value Pr(>|z|)
## (Intercept) -0.181719
                           1.137582
                                    -0.160 0.873085
                                     -2.789 0.005283 **
## Weight.x
               -0.008469
                           0.003036
## Reach.x
               -0.024836
                           0.012598
                                     -1.971 0.048676 *
## SLpM.x
               -0.329434
                           0.039865
                                     -8.264 < 2e-16 ***
## Str Acc.x
               -1.146719
                           0.528378
                                     -2.170 0.029987 *
## SApM.x
               0.271651
                           0.042549
                                      6.384 1.72e-10 ***
## Str_Def.x
               -1.360699
                           0.563618
                                    -2.414 0.015769 *
## TD_Avg.x
               -0.125197
                           0.029322 -4.270 1.96e-05 ***
## TD_Acc.x
                0.578959
                           0.185351
                                      3.124 0.001787 **
## TD_Def.x
               -1.061454
                           0.176487
                                     -6.014 1.81e-09 ***
## Sub_Avg.x
               -0.179261
                           0.048997
                                    -3.659 0.000254 ***
## Weight.y
                0.007413
                           0.003028
                                      2.448 0.014347 *
## Reach.y
                0.036872
                           0.012501
                                      2.950 0.003182 **
## SLpM.y
                0.343938
                           0.034296
                                     10.029
                                             < 2e-16 ***
## SApM.y
                           0.039325
                                     -7.268 3.66e-13 ***
               -0.285798
## Str_Def.y
                           0.539356
                                      2.087 0.036860 *
                1.125803
## TD_Avg.y
                0.131304
                           0.028207
                                      4.655 3.24e-06 ***
## TD_Def.y
                0.945587
                           0.176126
                                      5.369 7.93e-08 ***
                                      2.222 0.026259 *
## Sub_Avg.y
                0.107328
                           0.048295
##
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##
       Null deviance: 6742.9
                              on 4863
                                       degrees of freedom
## Residual deviance: 6095.7
                              on 4845
                                       degrees of freedom
## AIC: 6133.7
## Number of Fisher Scoring iterations: 4
```

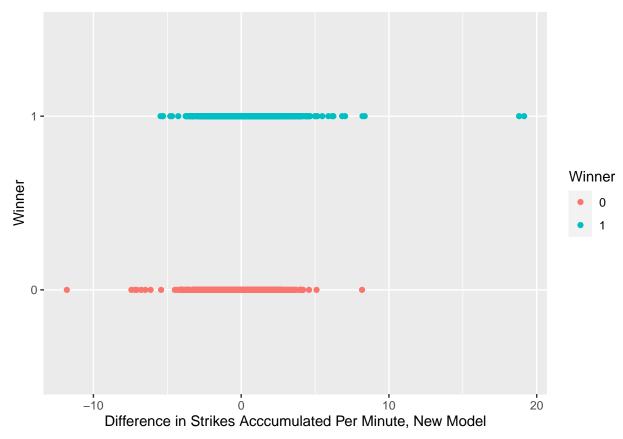
```
Rsq6 = 1 - logreg.mdl6$deviance/logreg.mdl6$null.deviance
Rsq6
```

[1] 0.09599186

Specificity: 0.6413088

```
Reducirani model ima manji AIC, no ima manji Rsq i veću rezidualnu devijancu. Provedimo LRT da vidimo
možemo li ga zadržati.
anova(logreg.mdl5, logreg.mdl6, test = "LRT")
## Analysis of Deviance Table
##
## Model 1: Winner ~ Fight type + Weight.x + Reach.x + Stance.x + SLpM.x +
       Str_Acc.x + SApM.x + Str_Def.x + TD_Avg.x + TD_Acc.x + TD_Def.x +
##
##
       Sub Avg.x + height cm.x + Weight.y + Reach.y + Stance.y +
       SLpM.y + Str_Acc.y + SApM.y + Str_Def.y + TD_Avg.y + TD_Acc.y +
##
       TD_Def.y + Sub_Avg.y + height_cm.y
##
## Model 2: Winner ~ Weight.x + Reach.x + SLpM.x + Str Acc.x + SApM.x + Str Def.x +
       TD_Avg.x + TD_Acc.x + TD_Def.x + Sub_Avg.x + Weight.y + Reach.y +
       SLpM.y + SApM.y + Str_Def.y + TD_Avg.y + TD_Def.y + Sub_Avg.y
##
##
     Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1
          4765
                   5984.9
## 2
          4845
                   6095.7 -80 -110.78 0.01294 *
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
Vidimo da ako koristimo razinu značajnosti 0.05, možemo koristiti reducirani model. Provjerimo sada kakav
je naš model u predviđanju
yHat <- logreg.mdl6$fitted.values >= 0.5
tab <- table(final_data3$Winner, yHat)</pre>
tab
##
      yHat
##
       FALSE TRUE
     0 1568 867
##
##
     1
         877 1552
accuracy6 = sum(diag(tab)) / sum(tab)
precision6 = tab[2,2] / sum(tab[,2])
recall6 = tab[2,2] / sum(tab[2,])
specificity6 = tab[1,1] / sum(tab[,1])
cat("Accuracy: ",accuracy6,"\n")
## Accuracy: 0.6414474
cat("Precision: ",precision6,"\n")
## Precision: 0.6415874
cat("Recall: ",recall6,"\n")
## Recall: 0.6389461
cat("Specificity: ",specificity6,"\n")
```

```
ggplot(data = final_data3, aes(x = SApM.x-SApM.y, y = Winner, color = Winner)) +
geom_point() +
labs(x = "Difference in Strikes Accoumulated Per Minute, New Model", y = "Winner")
```



PRIMJER ZNAČAJNOG REGRESORA

Primjećujemo da sada podjednako dobro pogađa i za crvene i za plave kada je tko pobijedio. Reccall je dosta bolji za ovakav model, dok su ostali parametri slični kao prije. Za pogađanje pobjednika mi bi koristili model koji ne zna tko je u kojem kutu, jer ima puno bolji recall.

Sada dolazimo do glavnog pitanja, možemo li pomoću ovakvog modela i dostupnih značajki pogoditi pobjednika UFC borbe? Mi ne bi rekli da možemo pogoditi sa 100% sigurnošću (a ne bi ni model, naprotiv, on kaže 64.47%), jer UFC borba je puno više od same statistike i nama dostupnih značajki, no, ovaj model nam može dati čvrstog favorita što je bolje od pogađanja.

Bonus zadatak 5. - Postoji li veza između postotka obranjenih udaraca u karijeri borca (Str_Def) i značajnih primljenih udaraca po minuti u karijeri borca (SApM)?

Zanima nas možemo li ustanoviti da borci s velikim Strike Defensom često imaju manji broj primljenih udaraca po minuti u karijeri. Za ispitivanje ovog zadatka koristit ćemo model linearne regresije s kojim ćemo pokušati vidjeti je li Str_Def značajan u predviđanju SApM.

Za početak učitavamo podatke i formatiramo dataframe da sadrži stupce imena borca, njegovog SApM i Str Def. Filtriramo one borce za koje ti podatci ne postoje.

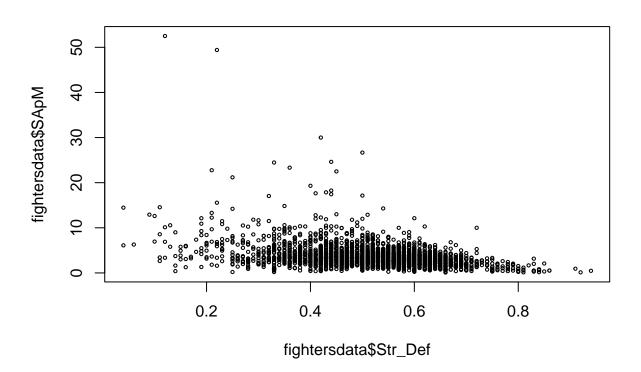
```
fightersdata=read.csv("fighter_details.csv")
```

```
fightersdata=fightersdata[c("fighter_name", "SApM", "Str_Def")]
fightersdata$Str_Def=parse_number(fightersdata$Str_Def)/100#postotak u decimale
fightersdata <- filter(fightersdata, fightersdata$SApM > 0)#mičemo fightere koji nemaju
fightersdata <- filter(fightersdata, fightersdata$Str_Def > 0)
summary(fightersdata)
```

```
##
    fighter_name
                              SApM
                                              Str_Def
    Length:2915
                                : 0.100
                                                   :0.0400
##
                                           Min.
                         Min.
##
    Class : character
                         1st Qu.: 2.250
                                           1st Qu.:0.4500
##
          :character
                         Median : 3.160
                                           Median :0.5300
##
                                : 3.659
                                                   :0.5176
                         Mean
                                           Mean
                         3rd Qu.: 4.320
##
                                           3rd Qu.:0.6000
##
                         Max.
                                 :52.500
                                           Max.
                                                   :0.9400
```

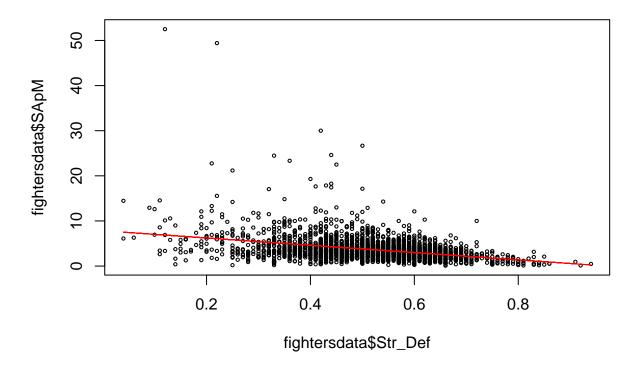
Pogledajmo odnos varijabli pomoću scatter plota. Nezavisna varijabla u našem slučaju je Str_Def. Iz priloženog grafa vidimo da postoji odnos između dvije varijable i nagađamo da je linearna. Što je veći Str_Def pretpostavljamo da će biti manji SApM. Također vidimo da postoje outlieri koji imaju izrazito veliki SApM za određeni Str_Def.

```
plot(fightersdata$Str_Def,fightersdata$SApM,cex=0.45)
```



Namjestimo sada linearni model. Prema grafu možemo pretpostaviti da pravac dobro opisuje odnos.

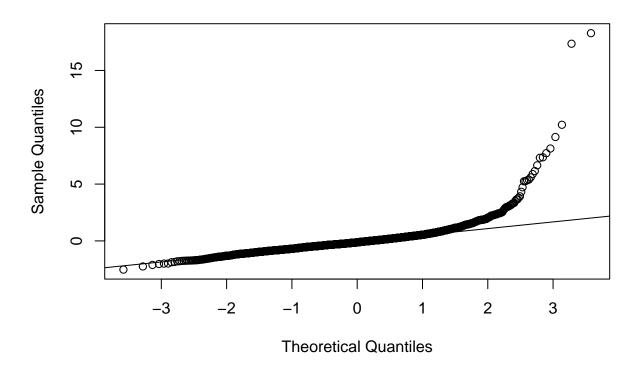
```
fit.St = lm(SApM~Str_Def,data=fightersdata)
plot(fightersdata$Str_Def,fightersdata$SApM,cex=0.45) #graficki prikaz podataka
lines(fightersdata$Str_Def,fit.St$fitted.values,col='red') #graficki prikaz procijenjenih vrijednosti i
```



Primjećujemo da postoji odnos, no da je varijanca velika i da postoji određen broj outliera. Provjeravamo normalnost reziduala.

```
#q-q plot reziduala s linijom normalne distribucije
qqnorm(rstandard(selected.model))
qqline(rstandard(selected.model))
```

Normal Q-Q Plot



```
lillie.test(rstandard(fit.St))
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: rstandard(fit.St)
## D = 0.13905, p-value < 2.2e-16</pre>
```

Lilliefors testom dolazimo do zaključka da naši reziduali nisu normalno distribuirani.

summary(fit.St)

```
##
## lm(formula = SApM ~ Str_Def, data = fightersdata)
##
## Residuals:
      Min
              1Q Median
                            3Q
##
                                  Max
## -6.308 -1.214 -0.315 0.766 45.631
##
## Coefficients:
##
               Estimate Std. Error t value Pr(>|t|)
                7.8378
                            0.2059
                                     38.06
                                             <2e-16 ***
## (Intercept)
                            0.3876
                                  -20.83
## Str_Def
                -8.0729
                                             <2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 2.501 on 2913 degrees of freedom
```

```
## Multiple R-squared: 0.1296, Adjusted R-squared: 0.1293
## F-statistic: 433.8 on 1 and 2913 DF, p-value: < 2.2e-16</pre>
```

Nakon obavljenog summary-a, imamo sljedeće činjenice. Reziduali nam nisu normalno distribuirani, nemamo veliki R-squared, no Str_Def je jako značajan po p-vrijednosti i imamo jako malu p-vrijednost u F statistici. Ovaj model nije najbolji za predviđanje borčevog SApM, no to nije ni bio cilj istraživanja. Cilj je bio pokazati da postoji veza između Str_Def i SApM, i sudeći po rezultatima ove linearne regresije vidimo da je Str_Def vrlo značajan za vrijednost SApM(<2e-16). Po tome zaključujemo da Str_Def igra ulogu u određivanju SApM. Naša pretpostavka zašto model za predviđanje nije još dovoljno dobar je da je potrebno još varijabli koje bi objasnile varijancu, što ostavljamo za buduća istraživanja.